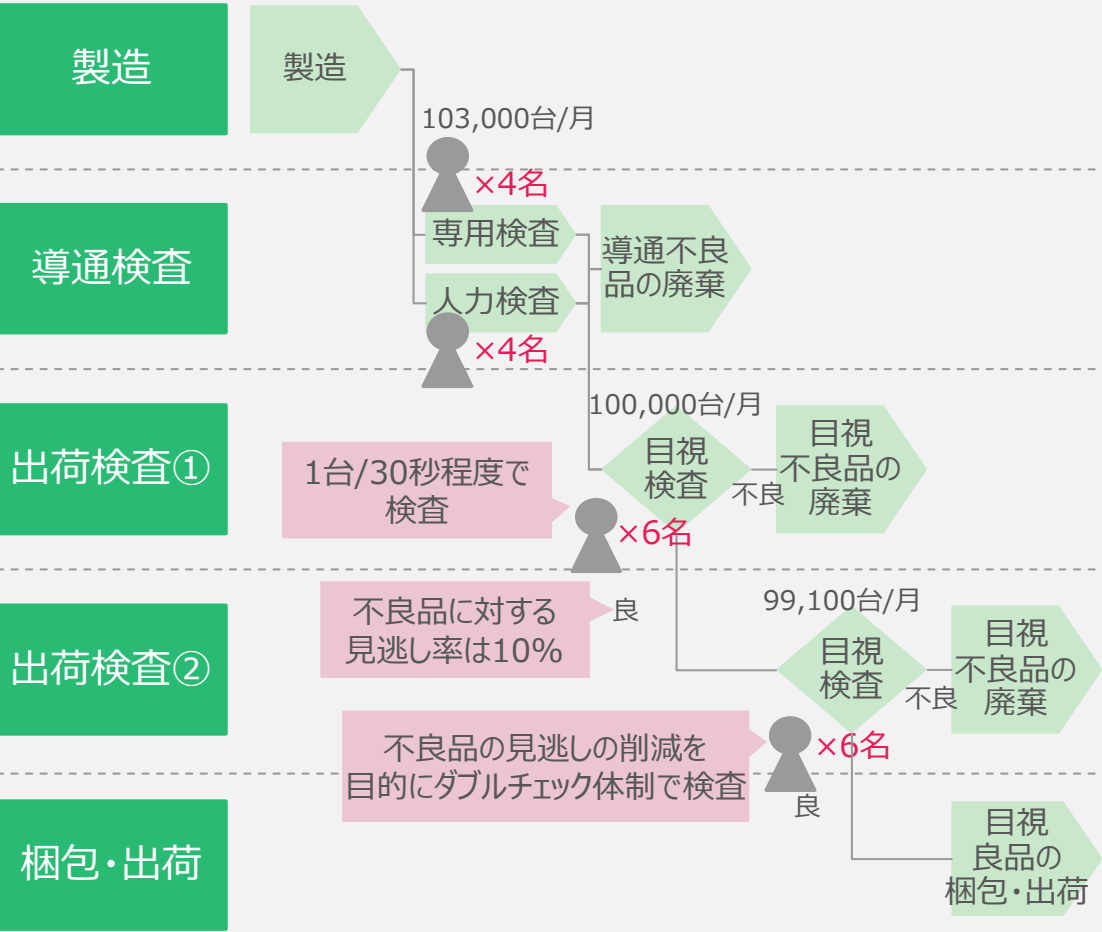


※事務局注：本ページの内容は、一定以上の精度のモデルを構築できたとした場合のイメージです

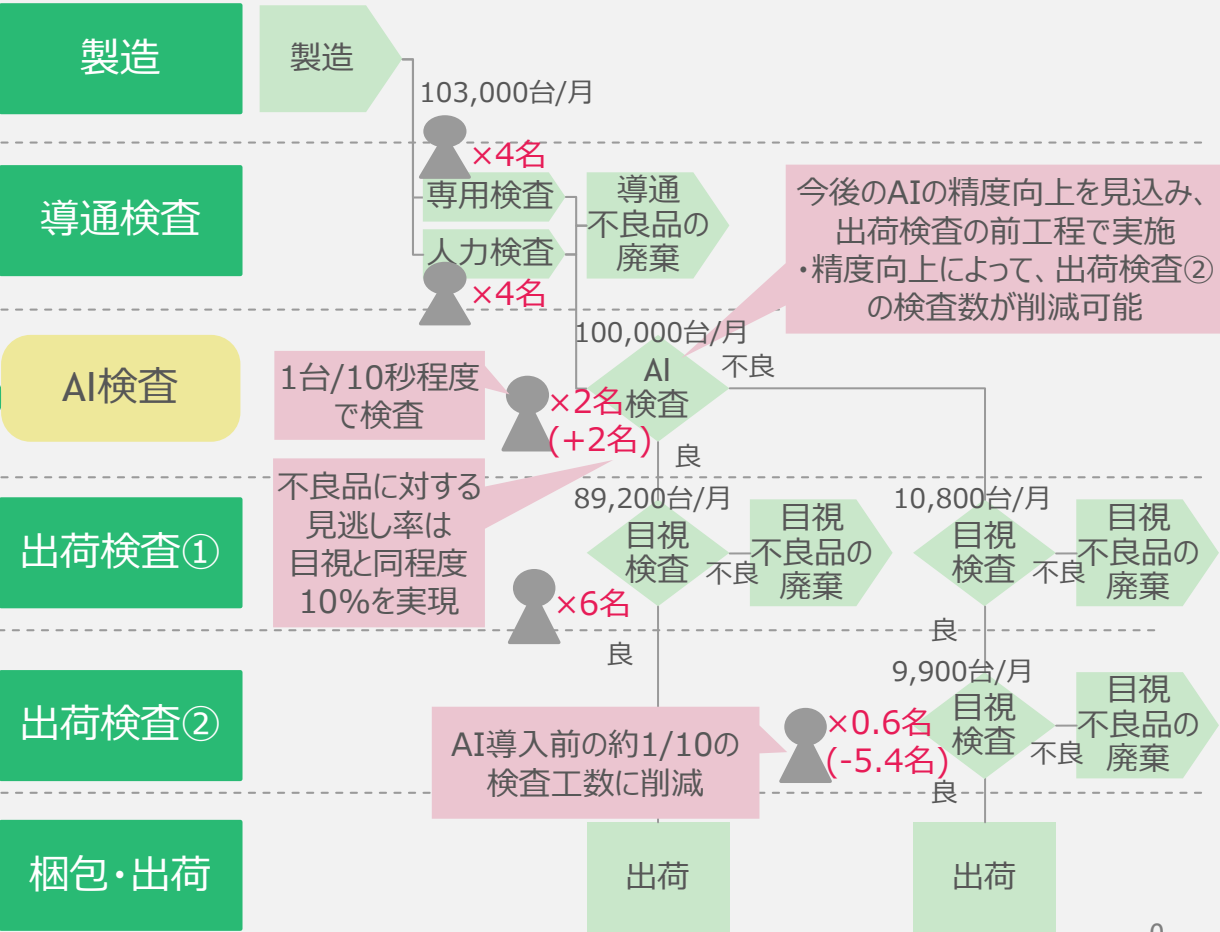
提出課題⑤-2-1：AI実装前後の業務プロセス設計の現状／あるべき姿の策定

解答例（あくまで一例です） ⑤-2-1. AI実装前後の業務プロセス設計の現状／あるべき姿の策定

現状



あるべき姿




Tips) 実際の工場現場における外観検査効率化の実装例

外観検査の自動化の方法として「Webカメラ等汎用品と画像AIモデルを組み合わせる方法」「専用検査装置を購入する方法」の2つがあります。どちらも「検査工程の手間・時間・コストを削減する」といった目的は同じです。

専用検査装置は、検査に特化した装置であり、当然ですが外観検査に必要なスペックを満たしています。しかし、**数百万～数千万円するものもあり**高価で柔軟性が低いというデメリットがあります。

近年はデジタル化が進み、高性能かつ安価なカメラや、無償のカメラ制御用ソフトウェアライブラリの入手が容易になっています。これら汎用品と今回開発したAIモデルを組み合わせることで、検査対象物の変更や追加を柔軟に行うことが可能です。
さらに、価格は数十万円程度に抑えることが出来るでしょう。

汎用品を組み合わせた機器構成例

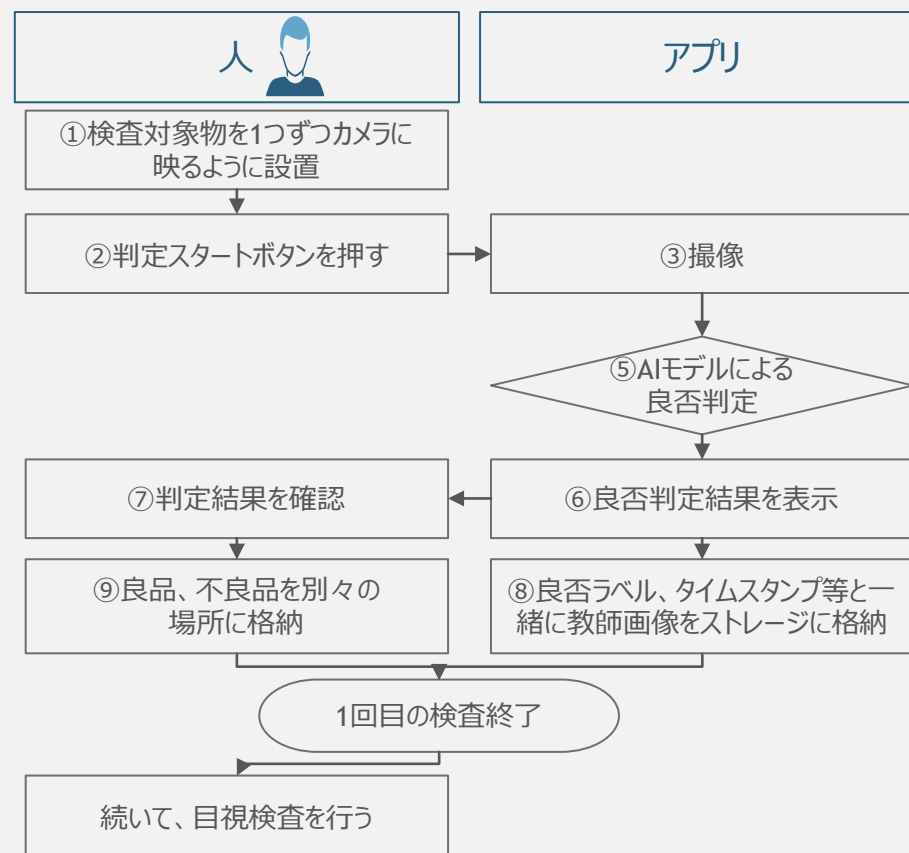


機器要件（例）

- 画像解像度 300×300 ～ 800×800 pixel程度
- 撮影時間 ～3秒
- USB接続のカメラを一般的なパソコンで制御

カメラでの画像撮影やノートパソコンで10秒程度の簡単な操作で検査可能

PythonやC++に画像処理ライブラリを取り込み、カメラとAIモデルを制御



提出課題⑤-2-2：業務効果の算出

解答例（あくまで一例です）⑤-2-2. 業務効果の算出

要件定義で設定した精度目標に対し、開発したモデルが目標を達成できているかで、導入の実施可否を決定します。
その上で、実施の場合は、以下の定量・定性面での効果を再検討・再算出しましょう。

- 定量効果 (提出課題③:要件定義より)
 - 出荷検査に12人/月かかっていたところ、出荷検査の前工程にAIを導入することで、出荷検査3.4人/月を削減
 - 出荷検査②において検査対象数99,100台/月・6人/月から、9,900台/月・0.6人/月に削減で、5.4人/月分の工数を削減
 - AI検査は1台/10秒程度で検査可能で、検査対象数100,000台/月、2人/月の工数が発生
 - 一人あたり人件費を500万円と想定し、 $500\text{万円} \times 3.4\text{人/月} = 1,700\text{万円/年}$ の工数削減効果
- 定性効果 (提出課題②:AI化業務の具体化より)
 - 従業員の満足度・定着率の向上
 - 突発的な欠勤等の低減による生産計画の安定化

提出課題⑤-2-3：システム実装・運用設計

解答例（あくまで一例です）⑤-2-3. システム実装・運用設計


1. 画像データの蓄積
 - －画像データは順次増加し、相当量のファイル容量となるため、良品画像データ及び不良品画像データを格納するファイルサーバーを予め用意しておく
 - －学習用データの蓄積及び精度監視のために、各画像に対する目視での最終判定後データ、AI判定結果データを記録しておく
2. AIモデルの管理
 - －新たに導入したAIモデルの精度が著しく悪いような事態に備え、古いバージョンのAIモデルを新しいモデルに書き換えていくのではなく、古いモデルを含めて複数のモデルをバージョン毎に管理する
3. 精度監視
 - －AIが誤って判定した製品は可能な限り実物を一定期間保管し、人が目視で精度劣化の有無を監視できるようにする
 - －人の判定結果とAIの判定結果が異なるケースが増えてきた場合には、モデルを置き換える
4. モデルのアップデート
 - －検品ラインを止めることはできないので、精度劣化したタイミングで都度学習させるのではなく、定期的に再学習を行ったモデルを作っておき、劣化認知のタイミングでモデルの入れ替えを行う
 - －劣化認知のタイミングでのモデル入れ替え時には、従来版と、アップデート版のモデルを並行で運用し、正しく判定がされているかを担保をしながら、入れ替えを行っていく

ガイドコンテンツ: モデル特性の分析方法

混同行列による誤検出傾向の確認（4分類のモデルの場合）
混同行列で確認する理由は、モデルが何に対して誤検出しているかを把握するため。

目視での検出可否傾向の確認（4分類のモデルの場合）
目視で確認する理由は、精度評価だけでは分からないモデルの得意不得意を理解するため。

モデルが判定した分類




例:

- ①良品を誤って不良品と判定している傾向
- ②芋はんだの判定に誤りが多く、角はんだと判定している傾向

芋ハンダ

良品




例1：
影が掛かっている場合は判定を誤る傾向

アノテーション

モデルの検出結果

角ハンダ

芋ハンダ



例2：
反射がある場合は角ハンダを芋ハンダと誤る傾向