

ガイドコンテンツ


目次

1. ベアリング損傷データの特徴について
2. EDA（データ可視化）
3. 故障予兆検知モデルについて
4. 精度評価指標について
5. 故障予兆の特徴量分析/要因分析について
6. 実際の工場現場における振動・音響データの取得方法の例

ベアリングの損傷の特徴について

ベアリングの損傷の種類

転動体タイプのベアリングの場合、主に、外輪傷、転動体傷及び内輪傷の3つの損傷の種類があります。
損傷の種類によって、発生する振動波形の特徴が異なります。



転動体ベアリングのイメージ図¹⁾



外輪傷²⁾



転動体傷³⁾




内輪傷²⁾

注：写真はイメージの例

ベアリングの損傷データの特徴量の求め方：エンベロープ解析（1/2）

ベアリングの内部に損傷が生じると、転動体が回転に伴って損傷の部位と衝突する事で、衝撃的な振動が発生します。



内輪傷の部位に転動体が衝突する局部の拡大イメージ^{1,4)}


損傷による衝撃波形の発生イメージ⁴⁾

* 固有振動数とは、物体が持つ固有の共振周波数で、この周波数では、一旦外力が生じると、外部から力を加えなくても自分自身だけで振動し続ける。

ベアリングの損傷データの特徴量の求め方：エンベロープ解析（2/2）

振動の生波形だけでは損傷による衝撃波形のパルスの周期を検出することが難しいので、振動波形のエンベロープ（包絡線）の周波数解析を行うことで、損傷による衝撃波形の特徴を掴むことができます。実際の計測データは損傷により発生した衝撃波形に機械の固有の振動が加わるのでより複雑な波形となります。

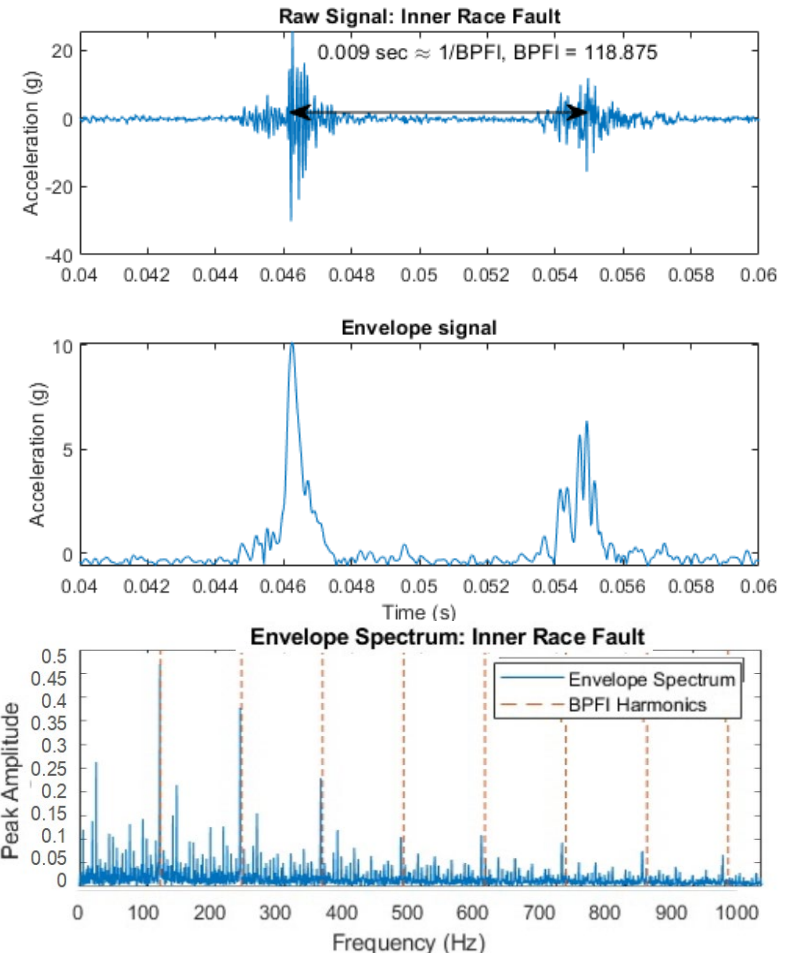
参照コード⁵⁾ : from scipy import signal
 envelope = abs(signal.hilbert(data))



損傷による衝撃波形のエンベロープ解析のイメージ⁴⁾

注：出典2)の図に文字と線を加筆

損傷による衝撃波形 (左図)
 +
 機械の固有振動
 →




内輪傷の発生時の振動波形の計測データ例¹⁾

ベアリングの損傷データの特徴量の求め方：スペクトログラム解析

スペクトログラムは、振動波形の局所的な時間における周波数成分と、その経時的な変化を3次元のグラフ（横軸：時間、縦軸：周波数、コンターの色：スペクトル強度、即ち信号成分の強さ）で示したものです。エンベロープは損傷による衝撃的な振動の周期の特定に役立ちますが、スペクトログラムは周期の情報に加えて、周波数の変化も同時に特定することができます。

弱  強

参照コード⁷⁾ : `import numpy as np`
`from scipy import signal`
`f, t, Sxx = signal.spectrogram(x, fs)`



出典6)の図に文字と線、凡例のイメージを加筆


スペクトログラム解析のイメージ⁶⁾ (周波数が5秒ごとに、10Hz、25Hz、50Hz、100Hzへと変化する信号)

EDA（データ可視化）


データの可視化

- データを可視化することで、正常時と故障予兆時の特徴量の違いを把握することが重要である。振動データの特徴量として、周波数、エンベロープ、スペクトログラムなどが挙げられます。

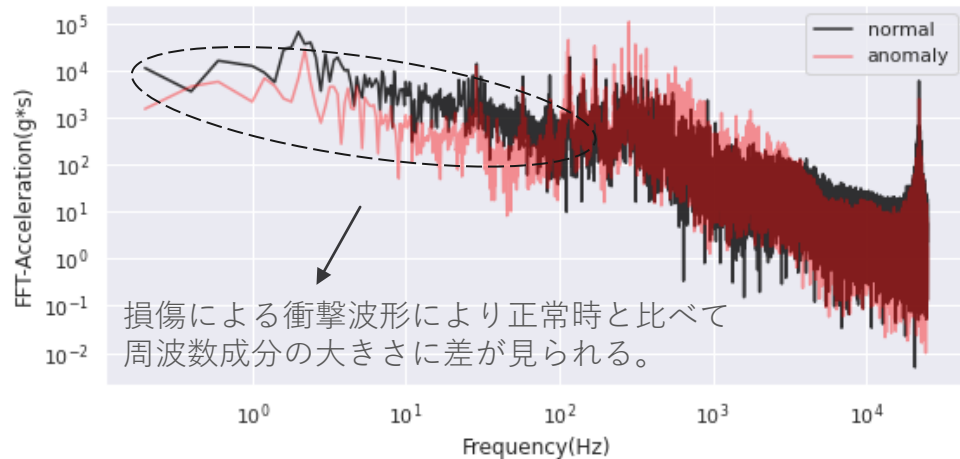
正常時と故障予兆時の時刻歴



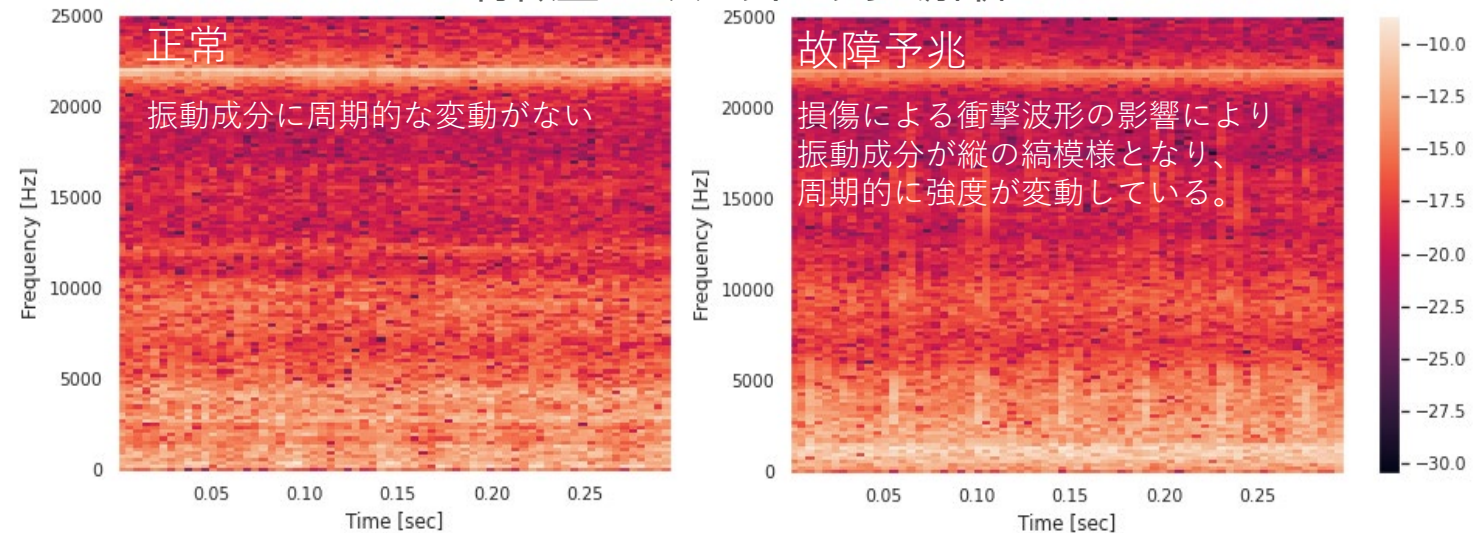
特徴量2:エンベロープ解析



特徴量1:周波数解析



特徴量3:スペクトログラム解析

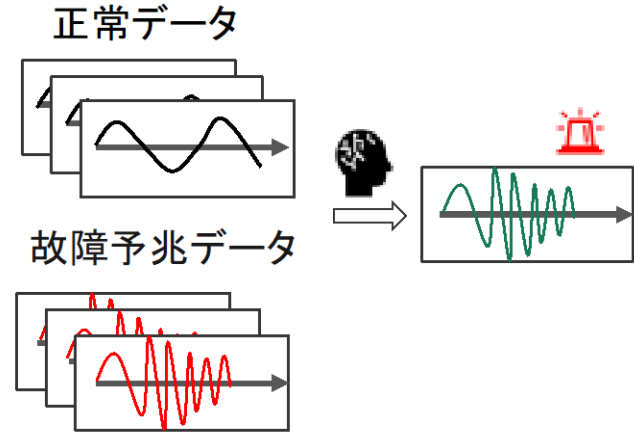
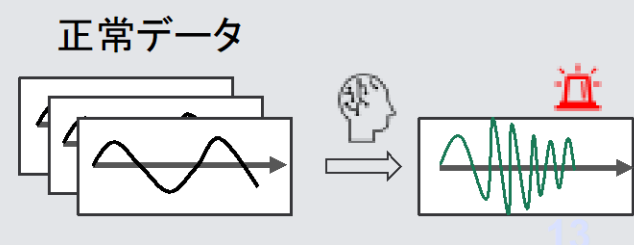


故障予兆検知モデルについて

故障予兆検知モデルの種類


正常とor故障予兆の2値分類問題として故障予兆検知を行う場合、正常時のデータと故障予兆時のデータの両方を学習させる教師あり学習と、正常時のデータだけを学習させる教師なし学習の2パターンがあります。データの取得状況や検知したい故障予兆の種類により最適な手法を検討する必要があります。

分類問題における故障予兆検知モデルの比較

種類	特徴	メリット	デメリット	アルゴリズムや手法	イメージ
教師あり学習	あらかじめ正常か故障予兆かのラベルづけがされたデータを学習しておき、未知のデータがどちらに分類されるかを判別する手法である。	正常と故障予兆のデータの数がある程度確保できる場合、学習精度が高く、学習速度も早い。	検知したい故障予兆のパターンを幅広く学習させておく必要があり、未知の故障予兆のパターンは検知できない。	Random Forest、SVM (Support Vector Machine)、NN(neural network) 等	
教師なし学習	正常時のデータの特徴を学習しておき、そこから逸脱する状態や変化を故障予兆として検知する手法である。	学習させていない未知の故障予兆のパターンにも対応できる。	故障予兆について正解を与えて学習できないので、学習の制御及び精度の判断が難しい。	OC-SVM (One Class SVM)、GMM (Gaussian Mixture Model)、AE (Auto Encoder) k-NN (k-Nearest Neighbor) 等	

AIモデルの適用イメージ

前頁の学習データを用いて構築したAIモデルを用い、リアルタイムで故障予兆検知を実施するモデルを構築します。



精度評価指標について

精度評価指標の種類

CONFIDENTIAL

正常とor故障予兆の2値の分類問題として故障予兆検知を行う場合、Accuracy、Precision、Recall、F1、AUCなどの評価関数が精度評価指標の候補となります。

精度評価指標の比較

評価指標	算定方法	定義	特徴
Accuracy	$Accuracy = (TP + TN) / (TP + FP + TN + FN)$	故障予兆・正常の正解率を表す。	<ul style="list-style-type: none">・直感的に理解しやすく解釈もしやすい。・不均衡データで漏れが生じる。
Precision	$Precision = TP / (TP + FP)$	故障予兆と予測したもののうち、どの程度正しかったかを表す（適合率とも言う）。	<ul style="list-style-type: none">・無駄打ちをなくするのが目標。・抜け漏れがあっても高い数値を返す。
Recall	$Recall = TP / (TP + FN)$	全故障予兆に故障予兆が実際どの程度含まれていたかを表す（網羅率、感度とも言う）。	<ul style="list-style-type: none">・機会損失をなくするのが目標。・誤検知があっても高い数値を返す。
F1	$F1 = 2 * Precision * Recall / (Precision + Recall)$	PrecisionとRecallの調和平均で表す。	<ul style="list-style-type: none">・PrecisionとRecallがバランス良く高い値の場合はF値も高い。・PrecisionとRecallの片方が高くとも片方が著しく小さいとF値は小さい。
AUC	ROC-AUC: ROC曲線を用いたAUC PR-AUC: PR(Precision-Recall)曲線を用いたAUC	ROC曲線の積分値であり、機械学習の判別性能を表す。	<ul style="list-style-type: none">・事前に分類の閾値を決めずに、閾値をずらしながら分類予測がどう変化していくかを見ることでモデルの評価を行う。

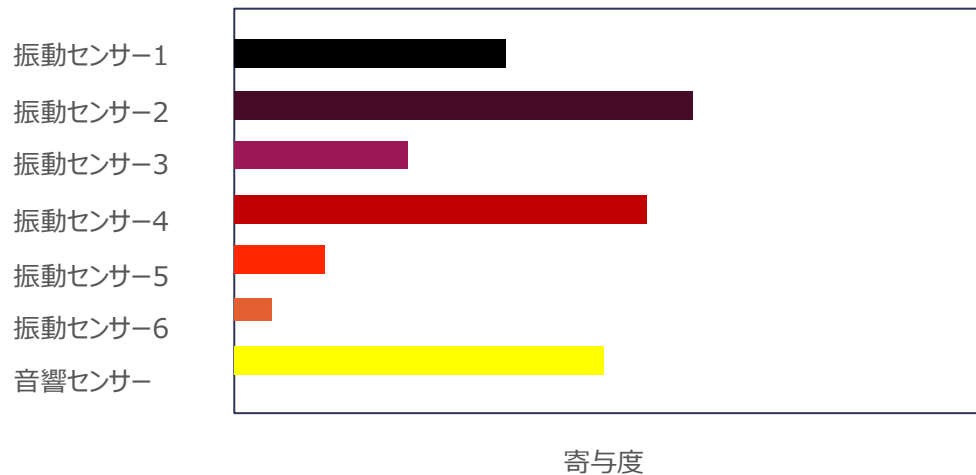
故障予兆の特徴量分析/要因分析について

故障予兆の特徴量分析/要因分析

故障予兆検知の結果に対して、各説明変数の寄与度を可視化します。これにより、構築したAIモデルの説明性が高まったり、故障予兆への貢献度の大小を見することで、特徴量の検討に利用できる可能性があります。モデルの予測への各説明変数の寄与度を可視化する指標として、Feature importanceやShapなどの指標があります。

ただし、これらの指標は特徴量と目的変数の相関関係があることを示していますが、実際の因果関係を保証するものではないため、ドメイン知識に基づく要因分析結果の解釈も併せて実施する必要があります。

モデルの予測への各説明変数の寄与度



目的変数に寄与する主な説明変数

目的変数	寄与する説明変数
故障予兆	振動センサー2、 振動センサー4、 音響センサー

注：図表はイメージの例

実際の工場現場における振動・音響データの取得方法の例

実際の工場現場における振動・音響データの取得方法の例

近年はIT化の取り組みの中、高性能かつ安価な振動センサーや音響センサーの入手が容易になっています。実際の工場現場ではこれらの市販品を使用することで簡単にデータを取得し、随時蓄積することが可能です。

音響センサーの要件（例）

- 周波数範囲：10Hz～50kHz
- 最大音圧レベル：128 dB

音響センサー



振動センサーの要件（例）

- 振動数範囲：10Hz～50kHz
- 測定レンジ：980m/s² rms



振動センサー

データの蓄積



参考文献

- 1) MathWorksサポートHP: 転動体ベアリングの故障診断, <https://jp.mathworks.com/help/predmaint/ug/Rolling-Element-Bearing-Fault-Diagnosis.html> (2021年7月15日参照)
- 2) Machinery Failure Prevention Technology Society: Fault Data Sets, <https://www.mfpt.org/fault-data-sets/> (2021年7月15日参照)
- 3) JTEKT: 技術・ご購入サポート, <https://koyo.jtekt.co.jp/support/faq/article/001678.php> (2021年7月30日参照)
- 4) 堀田智哉: 軸受の寿命と振動(2), WEBマガジン「新川タイムズ」, https://www.shinkawa.co.jp/times/2019_10column_bearing (2021年8月9日参照)
- 5) Qiita: Pythonで波形の包絡線, <https://qiita.com/ko-da-k/items/9715f8c74bef47b1ffec> (2021年9月7日参照)
- 6) 御法川学・伊藤孝宏: 装置設計者のための騒音の基礎 第30回, <https://www.cradle.co.jp/media/column/a282> (2021年8月16日参照)
- 7) Qiita: 短時間フーリエ変換を用いたスペクトログラムとPython実行方法の概要, https://qiita.com/purple_jp/items/7c91a05c547615e9ab89 (2021年9月7日参照)