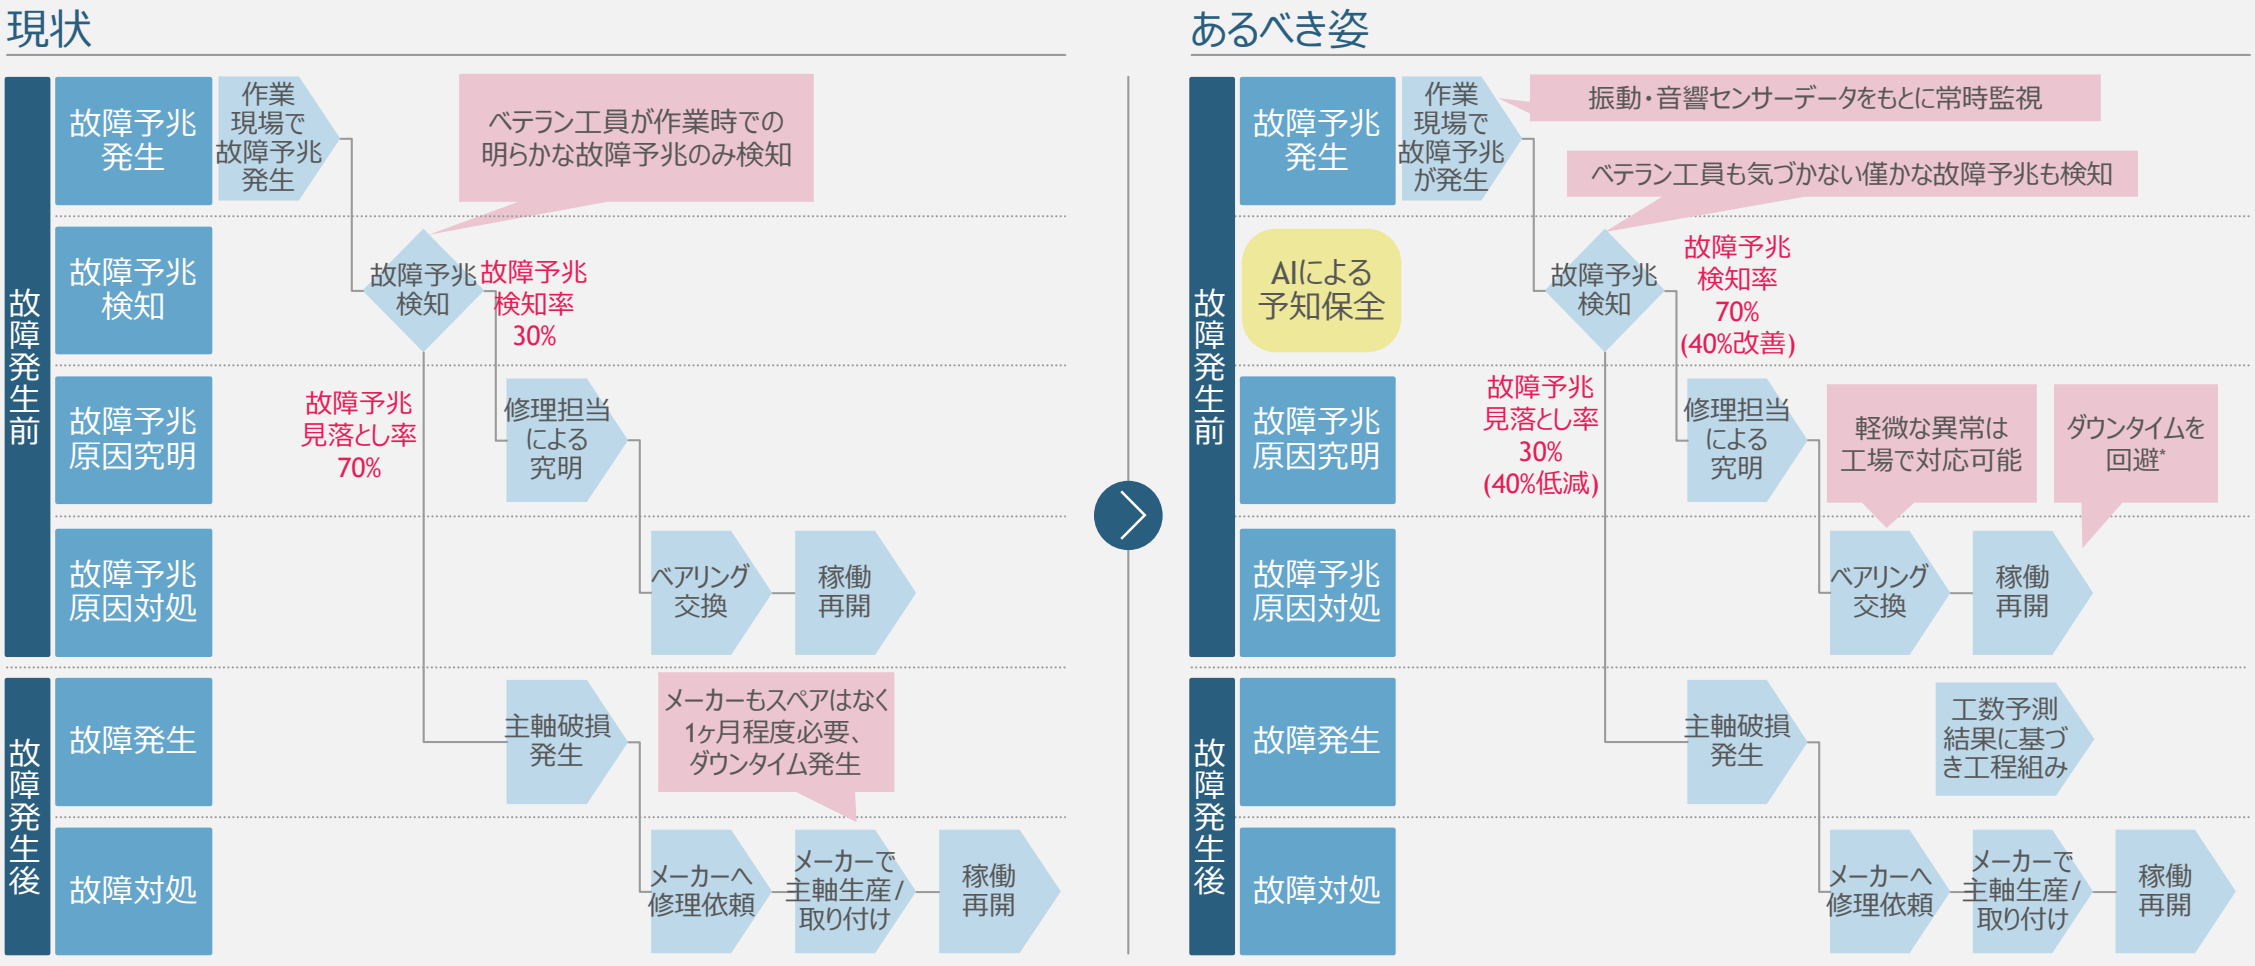


# 提出課題⑤-2-1: AI実装前後の業務プロセス設計の現状/あるべき姿の策定

解答例 (あくまで一例です) ⑤-2-1. AI実装前後の業務プロセス設計の現状/あるべき姿の策定



\*) 実際は原因究明・対処で数時間程度のダウンタイムは発生するが、故障発生後と比較すると軽微

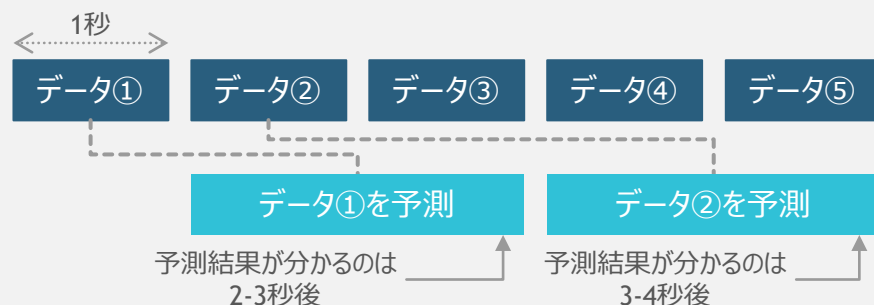
## 提出課題⑤-2-2: システム実装・運用設計 (1/3)

解答例(あくまで一例です) ⑤-2-3. システム実装・運用設計


### 1. データの持ち方・利用方法

- 可能な限りリアルタイムで判定させる想定のため、絶えず、"データ収集をしモデルへ入力"、"予測"、"予測結果に応じた反応"がループする動作を実現できるよう設計する
- よって、モデルの予測にかかる時間は、入力データの長さ[時間]よりも短くなるよう設計

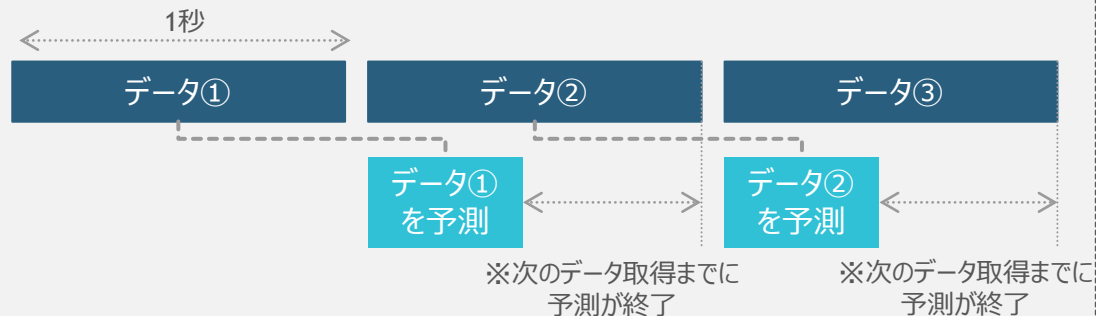
NG例: 予測結果が分かるタイミングがどんどん後ろ倒しとなっていく設計



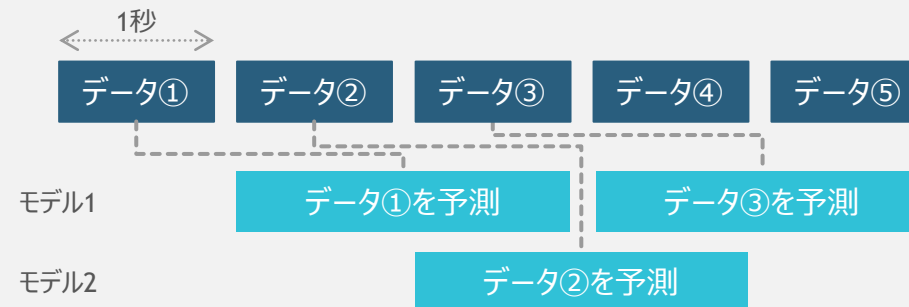
OK例②: 全時間列の予測をせず、一定時間ごと、直前の時系列の判定を行う設計



OK例①: 入力データの長さよりも予測時間が短く、直前の時間列の判定を行う設計



OK例③: 複数のモデルを用いて並列計算することにより、全時間列の判定を行う設計



## 提出課題⑤-2-2：システム実装・運用設計 (2/3)

解答例(あくまで一例です) ⑤-2-3. システム実装・運用設計

### 2. 精度監視

<モデルのパフォーマンスの監視>

- どのような観点で予測精度や予測モデルの傾向を監視するかを検討する。例えばF1scoreだけを見るのではなく、多角的にパフォーマンスを計測できるように、故障予兆の検知の正確さを示すprecisionや故障予兆の検知の網羅性を示すrecallといった他の評価尺度でも監視する。
- 全ての機械に対する平均精度を見るのではなく、機械ごとに個別に精度を監視する。

<モデルの異常の監視>

- モデルの予測精度だけではなく、振動・音響センサーより得られる時系列データの変化も監視し、計測センサー及び対象機器の状態の変化を素早く察知し、必要に応じイレギュラーなインプットへの対策を検討したり、誤った故障予兆の判定が連続に続いた場合は、AIモデルによる監視を中止し原因を調べる、といった対応を行う。

### 3. モデルのアップデート方法

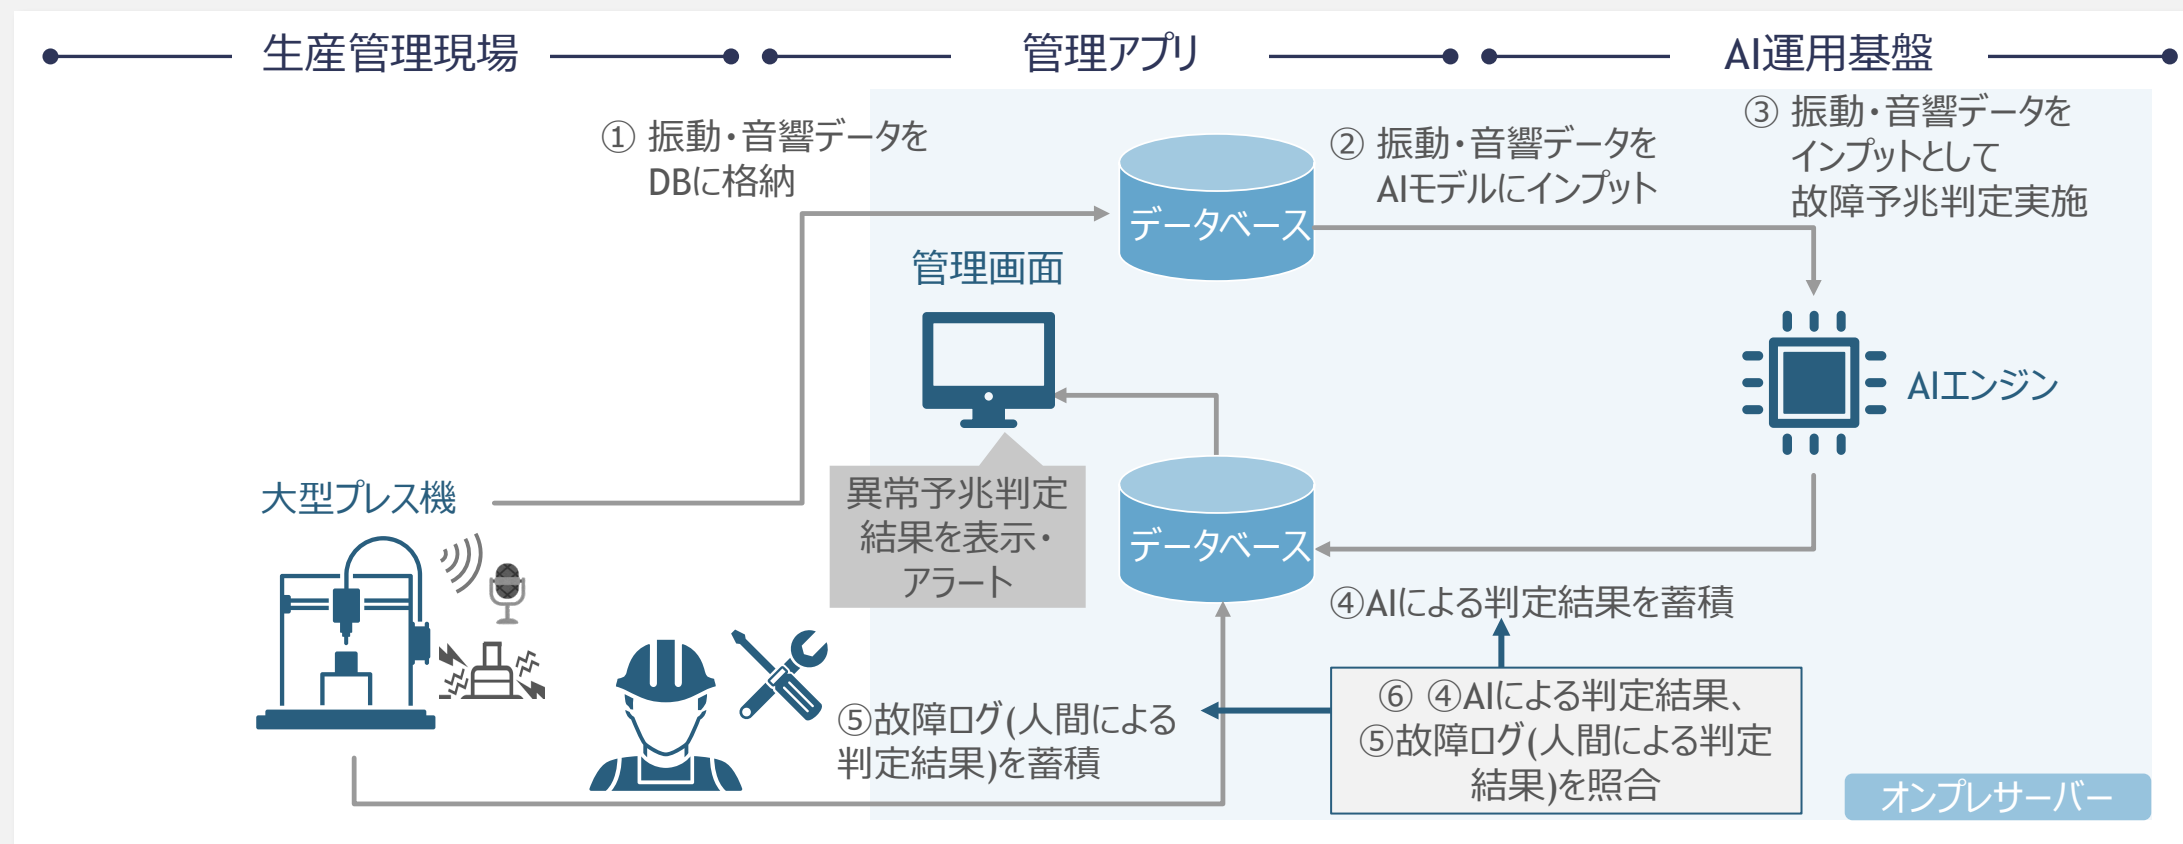
- 被加工物や加工方法等により機械から生じる振動や音の傾向が大きく変わった場合や、学習させた以外の故障予兆パターンが増えた場合は、予測精度が劣化する可能性がある。例えば、precisionとrecallのバランスで得られるコストメリットからF1の閾値を設定し、予測精度が〇〇まで劣化したら、新しい傾向のデータが十分な量を取得できるまでその機械へのモデル運用は停止し、取得後、迅速にモデルの再学習を実施する等、対応策・ルールを事前に検討しておく。
- 誤検知が頻出するようになった場合には業務に支障が生じる為、閾値の見直しやモデルの取り換えなどを行う。

その他、必要に応じ、システムの稼働率や障害が起こった時の対応、セキュリティレベル等の非機能要件についても、現場の状況に応じ、顧客の要求に合わせ、SIerと議論できるとよいでしょう。

## 提出課題⑤-2-2：システム実装・運用設計 (3/3)

解答例(あくまで一例です) ⑤-2-3. システム実装・運用設計

開発したモデルのAI実装の全体の構成が分かる以下のような図があると、クライアントに提案内容を理解してもらったり、システム構築をSIerに外注する際に全体像を説明するのに役立つでしょう



## 提出課題⑤-2-3：業務効果の算出 (1/3)

解答例(あくまで一例です) ⑤-2-2. 業務効果の算出

【定量効果】

ダウンタイム発生による売上ロスの低減：**5,000万円/年**

- 現状、大型プレスの主軸破損によるダウンタイムで発生している売上ロス：**①0.875億円/年**
  - 大型プレス機で製造している年間製品売上(=50億円/年×30%)×年間に対する主軸破損1回あたりの製造停止期間割合(=1ヶ月÷12ヶ月)×現状の年間あたりの主軸破損発生頻度(=1回/年×(1-ベテラン工員が故障予兆を検知できる確率30%)=0.7回/年)  
=15億円/年×(1ヶ月÷12ヶ月)×0.7回/年=0.875億円
- AIによる予知保全導入後に、大型プレスの主軸破損によるダウンタイムで発生すると想定される売上ロス：**②0.375億円/年**
  - 大型プレス機で製造している年間製品売上(=50億円/年×30%)×年間に対する主軸破損1回あたりの製造停止期間割合(=1ヶ月÷12ヶ月)×AI導入後の年間あたりの主軸破損発生頻度(=1回/年×(1-AIが故障予兆を検知できる確率70%)=0.3回/年)  
=15億円/年×(1ヶ月÷12ヶ月)×(0.3回/年)=0.375億円
- よって、AI導入による予知保全導入による売上ロスの低減：**0.5億円/年**
  - ①0.875-②0.375=0.5億円

修理費用の削減：**188万円/年**

- 現状、大型プレスの主軸に関連して発生している修理費用：**①359万円/年**
  - 現状の年間あたりの主軸破損発生頻度(=0.7回/年)×主軸破損時の1回あたりの修理費用(500万円/回)  
+ 現状の故障予兆検知時のベアリング修理頻度(=1回-0.7回/年)×故障予兆検知時のベアリングの1回あたりの修理費用(30万円/回)  
=0.7回/年×500万円/回+0.3回/年×30万円/回=359万円/年
- AIによる予知保全導入後に、大型プレスの主軸に関連して発生すると想定される修理費用：**②171万円/年**
  - AI導入後の年間あたりの主軸破損発生頻度(=0.3回/年)×主軸破損時の1回あたりの修理費用(500万円/回)  
+ AI導入後の故障予兆検知時のベアリング修理頻度(=1回-0.3回/年)×故障予兆検知時のベアリングの1回あたりの修理費用(30万円/回)  
=0.3回/年×500万円/回+0.7回/年×30万円/回=171万円/年
- よって、AI導入による修理費用の削減：**188万円/年**
  - ①359-②171=188万円

## 提出課題⑤-2-3：業務効果の算出 (2/3)

解答例(あくまで一例です) ⑤-2-2. 業務効果の算出

### 【定性効果】

納期遅延・クライアントへの信頼損失リスクの低減

- 現状、主軸破損でのダウンタイムによって起こる納期遅延・クライアントへの信頼損失を、AIによって主軸破損前に異常予兆を検知しダウンタイムを回避することで低減

業務属人化の解消

- 現状、ベテラン工員頼みだった異常予兆の検知をAIで代替することで、保全業務の属人化が解消

## 提出課題⑤-2-3：費用対効果の算出 (3/3)

解答例(あくまで一例です) ⑤-2-3. 費用対効果の算出

前頁で算出した業務効果と、以下の項目毎に費用を見積もり、費用対効果を算出する (費用項目は一例です)

イニシャルコスト

- AIモデル開発費
  - 人件費単価 x 稼働人員数 x 稼働期間に応じて算出
- アプリケーション開発費
  - AI管理アプリケーション (必要データの入力・出力、予測結果の管理画面上への表示・修正)

ランニングコスト

- AIの定期精度点検・アップデート費
  - 新規の故障予兆パターンが出てきた場合等
- 振動・音響センサー、ノートパソコンのメンテナンス・修理費、経年劣化による新規購入費
- アプリケーションサポート費
  - 開発したアプリケーション利用時のサポートサービス費 (問合せ、トラブル対応 等)

なお、ABC印刷側で必要な人員工数については、必要があれば別途算出