

大型プレス機の主軸破損における 予知保全AI導入のご提案

Agenda

1. AI導入プロジェクトの背景・目的
2. ご提案サマリー
3. 現状の整理
4. 提案内容
5. PoCで使用したデータの特徴
6. PoCで構築したモデルの詳細
7. 予防保全AIの導入ステップ
8. 効果(STEP1の実施をもって要再検討)
9. 費用(STEP1の実施をもって要再検討)

1. AI導入プロジェクトの背景・目的



ABC金属さまの悩み事

故障予兆に気付けないことにより発生している
ダウンタイム、修理費用、納期遅延リスクを低減したい



大型プレス機の主軸破損における予知保全

- ✓ ダウンタイムの回避による売上ロスの削減
- ✓ 主軸破損を事前に処置することによる修理費用の低減

※本PoCでは導入メリット・実現可能性を鑑みて一部の機械に絞る

2. ご提案サマリー

貴社製造ラインの計画的かつ安定した稼働の実現に向け、予知保全AIを実業務に組み込むためPoCを実施しました。

本PoCでは、実際の業務工程をヒアリングした結果を踏まえ、導入メリット・実現可能性を鑑み、大型プレス機の主軸破損に対して予知保全AIの導入を検証しました。

- 大型プレス機の主軸破損は故障発生時の修理期間が長く修理費用も高くかかる上、他機械での代替がきかないため故障回避によるメリットが大きい
- 工員より故障発生の予兆傾向が得られており、既存の振動・音響センサーを用いれば一定程度の実現可能性が見込める

検証結果としましては、本PoCで使用したデータに信頼性に欠ける特徴がみられたことから、現場作業の方の安全に関わる業務に対して本データを用いたモデルによる評価は今回実施致しません。データのとり直しをお願いしたく思います。

ただし、本PoCで検討したモデル構築を実施した場合、製造ラインを止める期間を短縮し、売上ロスの削減が実現可能な見込みです。

- ダウンタイムの回避による売上ロスの削減 0.21875億円/年
- 主軸破損の事前処置による修理費用の低減 87.5万円/年

3. 現状の整理

- 保全業務
 - 品質管理課 5名
 - 大型設備やロボットなどの複雑な機械は修理が難しくて部品も特殊なためメーカー対応が必要

対象機械	ブランキングプレス機	大型プレス機	小型プレス機	溶接ロボット	溶接機	塗装設備	組み立てロボット
		プレス工程		溶接工程		塗装工程	組み立て工程
台数	3台	1台	10台	約50台	約100台	約5台	約50台



故障パターン	潤滑油漏れ	金型破損	主軸破損	[主軸破損の要因]ベアリングの異常
発生頻度	1回/月	1回/月	頻度はそれほど高くない	予兆見逃し合わせて年1回/台程度 (故障予兆に気付くのは主軸関連の故障予兆全体の約30%)
修理担当者	品質管理課(修理担当)	品質管理課(修理担当)	機械設備メーカー	品質管理課(修理担当)
修理期間	1時間	予備品交換で数時間	1週間 メーカー在庫なし: 1か月	事前に気が付ければベアリング交換で1-2時間
修理費用	数万円程度	20万円程度	小型 50万円程度 大型 500万円程度	30万円程度

4. 提案内容

- 大型プレス機の主軸破損の予知保全はAI化の貢献が大きい
 - 故障発生時の**修理期間が長く修理費用も高く**かかる上、**他機械での代替がきかない**ため故障回避によるメリットが大きい
 - 工員より**故障発生の予兆傾向が得られて**おり、既存の振動・音響センサーを用いれば一定程度の実現可能性が見込める

 大型プレス機の主軸破損の予知保全のAI化をご提案

5. PoCで使用したデータの特徴


- 対象のデータ
 - 大型プレス機に設置した振動・音響センサーのデータ
 - 製造部で蓄積されている正常データと故障予兆データからある時間単位でランダムに抽出したもの
 - サンプリング周波数: 50kHz
 - データ長さ: 15,000行(0.3秒相当)

データ数		
train	正常(normal)	350
	異常(anomaly)	90
test	480	

正常データをsortしてuniqueにとってdiffした結果→
センサ分解能が0.00001で、15000サンプルあると重複するような癖を持つ

train-test間でその傾向があるため、本検証データの
正常/異常判別ロジックがその癖に引っ張られる

信頼性に欠けるデータは採用できないため、データの
とり直しをお願いしたく思います。



6. PoCで構築したモデルの詳細

※※ 前頁のデータを用いて構築した場合(今後の参考のため記載) ※※

- モデル構築

1. あらかじめ用意されたデータを元に、trainデータを水増し
(正常/異常データそれぞれが1000例になるように増やす)
2. trainデータから特徴量を抽出する手段としてtsfreshを利用
3. 得られた特徴量において、ある基準値を境にデータを分類

- 運用時のモデルでの分類

1. センサーのデータを用いて学習時と同様に、tsfreshで特徴量を抽出
2. 基準値を境にデータを分類
3. 異常音をセンサが拾ってから約30秒後には分類可能

本モデルによる正常/異常分類の運用は可能な想定

7. 予知保全AIの導入ステップ

※ 本PoCはデータが信頼性に欠けるためSTEP0とする

STEP1 データのとり直しによるモデル構築フェーズ

- 本PoCで構築した大型プレス機の予防保全AIは、現場作業者的安全に関わるため信頼性に欠けるデータは採用できない
- 次のSTEPに進む評価ポイント
 - 人手による故障予兆検知30%を達成する

STEP2 予防保全AIの本格導入フェーズ

- AI導入後の業務フロー整理およびUI工夫
- 実運用における検証実施(ただし、AIの結果をもとに最終確認は人が実施)
- 次のSTEPに進む評価ポイント
 - 人手による故障予兆検知30%を超える精度での故障予兆検知を達成する(STEP1の精度次第で目標数値は修正)(1台/年の故障発生率のため検証期間は目安1年)

STEP3 予防保全AIの他機械への展開フェーズ

- 大型プレス機以外の他機械に対して、予防保全AIのモデル構築を実施

8. 効果(STEP1の実施をもって要再検討)

STEP1にて人手による故障予兆検知30%を達成することにより、下記を実現

① ダウンタイムの回避→売上ロスの削減

大型プレス機で製造している年間製品売上(=50億円/年×30%)
×現状の年間あたりの主軸破損発生頻度(=1回/年×(1-ベテラン工員が故障予兆を検知できる確率30%)=0.7回/年)
×年間に対する主軸破損1回あたりの製造停止期間割合(=1ヶ月÷12ヶ月)×回避率(25%)
=15億円/年×0.7回/年×(1ヶ月÷12ヶ月)×0.25
=0.21875億円/年

② 主軸破損の事前処置→修理費用の低減

現状の年間あたりの主軸破損発生頻度(=1回/年×(1-ベテラン工員が故障予兆を検知できる確率30%)=0.7回/年)
×主軸破損時の1回あたりの修理費用(500万円/回)
×回避率(25%)
=0.7回/年×500万円/回×0.25
=87.5万円/年

9. 費用(STEP1の実施をもって要再検討)

- 費用

- 現時点では既存センサーのみの活用を想定しているため、追加のセンサー購入費は不要。
- モデル実装におけるPCのみの購入が必要(1台約20-30万円)